

単チャネル Cross-Relation 法に基づく時間周波数領域ブラインド残響除去*

©吉野夏樹, 矢田部浩平 (農工大)

1 はじめに

近年, さまざまなブラインド残響除去手法が進展している. それらの多くは複数マイクロホン構成を必要とし, さらに人間の音声の非定常性といった, 音源に対する統計的の仮定に依存することが多い. その結果, 楽器音などの非音声信号へ汎化させることは困難であった. これに対し本研究では, 単チャネル設定下における, 複数観測間の関係を利用したブラインド残響除去手法を提案する. 本アプローチでは, 単チャネル観測信号から切り出された複数の異なる音源信号の断片に対して, 単一の共通するインパルス応答が畳み込まれるという双対なシナリオを仮定する. この定式化を時間周波数領域で実装することにより, 長大残響に伴う空間計算量問題を効果的に解決する.

2 時間領域での Cross-Relation 法

一般に, SIMO (Single Input Multiple Output) システムにおけるブラインドチャネル同定手法として, Cross-Relation (CR) 法が知られている. 本来の CR 法は, 同一の未知音源信号 s が異なる室内インパルス応答 (RIR) h_1, h_2 を経て 2 つのマイクで観測される設定に基づき, $x_1 * h_2 - x_2 * h_1 = \mathbf{0}$ という関係式から音源 s を代数的に消去し, RIR の組を直接同定する手法である.

これに対し本研究では, 単一チャネル設定において, 音源信号と残響特性の数学的役割を反転させることで, CR 法をドライ信号の直接抽出へと応用する. 室内音響環境において, 単一のマイクで録音された残響信号 $x \in \mathbb{R}^n$ は, 未知のドライ信号 s と RIR $h \in \mathbb{R}^d$ の線形畳み込み $x = s * h$ としてモデル化される. ここで上記の畳み込みは可換であるため, 畳み込み行列 $M(\cdot)$ を導入すると, 次を得る: $s * h = M_d(s)h = M_l(h)s$.

本手法では, 同一の RIR h が畳み込まれた, 互いに素 (同一のベクトルとの畳み込みとして表現されないという意味で用いる) な 2 つの異なるドライ信号 $s_1 \in \mathbb{R}^{l_1}$ および $s_2 \in \mathbb{R}^{l_2}$ の区間を観測とし, それぞれの観測信号を次式とする:

$$x_1 = s_1 * h \in \mathbb{R}^{n_1}, x_2 = s_2 * h \in \mathbb{R}^{n_2} \quad (1)$$

このとき, 畳み込みの可換性より, 未知の RIR h を

代数的に消去した以下の CR 式が成立する:

$$\begin{aligned} x_1 * s_2 &= (s_1 * h * s_2) = x_2 * s_1 \\ \iff [M_{l_2}(x_2), -M_{l_1}(x_1)] \begin{bmatrix} s_1 \\ s_2 \end{bmatrix} &= \mathbf{0} \end{aligned} \quad (2)$$

上式における左辺の行列は, シルベスター行列 $A^{\text{time}}(x_1, x_2)$ として知られている. s_1 と s_2 が互いに素であるとき, この行列の零空間 (右特異ベクトル) を求めることで, スケール不定性を除いてドライ信号の組 $\begin{bmatrix} s_1^\top & s_2^\top \end{bmatrix}^\top$ を一意に復元可能である.

空間計算量の問題 しかしながら, 時間領域での畳み込みモデルに基づくブラインド残響除去には, 空間計算量の問題が存在する. 畳み込みの長さが d であるとき, シルベスター行列 A^{time} のサイズは $O(n_1 + n_2 - 2d) \times O(l_1 + l_2 - 2d)$ となる. 残響時間が長大な環境においては, RIR の長さ d が大きくなる. たとえば, ドライ信号と RIR の長さがそれぞれ 1 秒でサンプリング周波数が 20kHz の場合, シルベスター行列のサイズは X by Y となり, 倍精度浮動小数点数で 16GB 以上を占有することになる.

3 提案法

3.1 サブバンド畳み込みモデルに基づく定式化

時間領域単チャネル CR 法の空間計算量の問題を解決するために, 提案法では, 時間周波数領域でのサブバンド畳み込みモデルに基づく定式化を採用する. 各信号に対し, 離散ガボール変換 (DGT) を適用し, 時間周波数領域へ変換する. 各周波数ビン f において, 時間フレーム方向のサブバンド畳み込み近似が成り立つと仮定すると, TF 領域における観測信号 $x_f^1(n), x_f^2(n)$ は以下のようにモデル化できる [1].

$$x_f^1(n) \approx s_f^1(n) * h_f(n), \quad x_f^2(n) \approx s_f^2(n) * h_f(n) \quad (3)$$

ここで, n は時間フレームのインデックスであり, $s_f^1(n), s_f^2(n)$ はクリーン音声のサブバンド成分, $h_f(n)$ は時間フレーム方向に作用するサブバンドインパルス応答を表す. なお, このモデルはあくまで近似的なものであり, スペクトルのもれなどの影響により, 厳密な畳み込み関係は成立しないことを付記しておく.

*本研究は, 科学技術振興機構 (JST) 創発的研究支援事業 (JPMJFR****) の支援を受けて実施されたものである.

Algorithm 1 Subband Blind Deconvolution via SVD of Sylvester Matrix

Require: Subband observed signals $\mathbf{X}_{1f}, \mathbf{X}_{2f}$ at frequency bin f , filter length $\mathbf{l} = [l_1, l_2]^T$

Ensure: Estimated dry signals $\mathbf{v}_{1f}, \mathbf{v}_{2f}$ at frequency bin f

- 1: $A_X \leftarrow \|[\mathbf{X}_{1f}^T, \mathbf{X}_{2f}^T]\|_2$
- 2: $\mathbf{S}_f \leftarrow [\mathbf{M}_{l_1}(\mathbf{X}_{2f}) - \mathbf{M}_{l_2}(\mathbf{X}_{1f})] \triangleright$ Construct Sylvester matrix
// Extract the null-space vector
- 3: $[\mathbf{U}, \mathbf{\Sigma}, \mathbf{V}] \leftarrow \text{svd}(\mathbf{S}_f + \alpha \mathbf{I}, \text{"econ"})$
- 4: $\mathbf{v}_f \leftarrow \mathbf{V}(:, \text{end})$
// Recover the original scale
- 5: $\mathbf{v}_f \leftarrow A_X \cdot \mathbf{v}_f / \|\mathbf{v}_f\|_2$
// Decompose into the two dry signals
- 6: $\mathbf{v}_f^1 \leftarrow \mathbf{v}_f(1 : l_1), \mathbf{v}_f^2 \leftarrow \mathbf{v}_f(l_1 + 1 : \text{end})$
- 7: **return** $\mathbf{v}_{1f}, \mathbf{v}_{2f}, \gamma_f$

3.2 共通因子分解と Sylvester 行列の構成

続いて、第2節で紹介したCR法の理論より、共通のサブバンドインパルス応答 $\mathbf{h}_f(n)$ を消去するために、ベクトルの畳み込み演算に関する可換性 ($\mathbf{s}_f^1 * \mathbf{h}_f * \mathbf{s}_f^2 = \mathbf{s}_f^2 * \mathbf{h}_f * \mathbf{s}_f^1$) を利用すると、以下の関係式が導かれる：

$$\begin{bmatrix} \mathbf{C}(\mathbf{x}_f^2) & -\mathbf{C}(\mathbf{x}_f^1) \end{bmatrix} \begin{bmatrix} \mathbf{s}_f^1 \\ \mathbf{s}_f^2 \end{bmatrix} \approx \mathbf{0} \quad (4)$$

ただし、 $\mathbf{A}_f$ 以下のように定義される Sylvester 行列

$$\mathbf{A}_f \stackrel{\text{def}}{=} \begin{bmatrix} \mathbf{C}(\mathbf{x}_f^2) & -\mathbf{C}(\mathbf{x}_f^1) \end{bmatrix} \quad (5)$$

$\mathbf{C}(\mathbf{x}_f^1)$ および $\mathbf{C}(\mathbf{x}_f^2)$ は観測信号の複素スペクトル時系列から生成される Toeplitz 行列である。

上述の TF 領域での畳み込みモデルはあくまで近似であり、雑音が存在しない理想的な状況においてもスペクトルのもれなどの影響により、式(4)は厳密な解を持たないため、特異値分解 (SVD) を利用する。 $\mathbf{A}_f$ の SVD を $\mathbf{A}_f = \mathbf{U}_f \mathbf{\Sigma}_f \mathbf{V}_f^H$ としたとき、最小特異値に対応する右特異ベクトル $\mathbf{v}_{f,\min}$ (すなわち $\mathbf{V}_f$ の最終列ベクトル) をクリーン信号の推定解 $\hat{\mathbf{s}}_f^1, \hat{\mathbf{s}}_f^2$ として採用する：

$$\begin{bmatrix} \hat{\mathbf{s}}_f^1 \\ \hat{\mathbf{s}}_f^2 \end{bmatrix} = \mathbf{v}_{f,\min} \quad (6)$$


4 数値シミュレーション

4.1 シミュレーションの設定

提案法の有効性を確認するための数値シミュレーションを実施する。クリーン信号に対して室内イン

Table 1 Average execution time per set [sec] across different reverberation time (sec).

	0.3 s	1.0 s	1.9 s	2.3 s
WPE	0.46	0.93	4.29	5.12
Proposed	7.46	7.75	9.34	10.06
Lifting	54.10	193.77	492.38	625.02



パルス応答を畳み込み、加法的雑音が重畳された信号に対して、残響除去を行った結果を比較する。クリーン信号は MIDI 音源から生成された楽器音であり、RIR は実測されたものを使用する。観測信号はこれらのクリーン信号と RIR の畳み込みにより生成される。提案法の性能は、クリーン信号と推定された信号の SDR を評価することで評価する。サンプリング周波数は 12kHz, DGT のフレーム長は 512 サンプル、ホップサイズは 128 サンプルである。

4.2 結果

持続する音に対しても、提案法はクリーン信号と比較して高い SDR を達成した。図1と図2は、それぞれのクリーン信号、観測信号、復元信号のスペクトログラムを示している。これらの結果は、提案法が残響成分を効果的に除去し、クリーン信号の特徴を保持しながら復元できることを示している。

5 結論

単チャンネル設定におけるブラインド残響除去のための新しい手法を提案した。時間周波数領域でのサブバンド畳み込みモデルに基づく定式化により、長大残響環境下での空間計算量問題を解決しつつ、信号波形の過剰な抑制を回避した。

参考文献

- [1] X. Li, S. Gannot, L. Girin and R. Horaud, "Multi-channel Identification and Nonnegative Equalization for Dereverberation and Noise Reduction Based on Convolutional Transfer Function," in IEEE/ACM TASLP, **26**(10) pp.1755-1768, Oct. 2018,