

単チャネル Cross-Relation 法に基づく時間周波数領域ブラインド残響除去*

©吉野夏樹, 矢田部浩平 (農工大)

1 前書き

近年, 様々なブラインド残響除去手法の研究が進展しているが, その多くは複数マイクロホン構成を必要とするか, 音声の非定常性など音源に対する強い統計的仮定に依存している. そのため, 単チャネル設定や非音声信号に対して十分な残響除去性能を発揮することは困難であった. 本稿では, 畳み込みの性質を利用した, 音源の事前知識を要しない手法を提案する.

2 時間領域単チャネル Cross-Relation 法

SIMO (Single-Input Multiple-Output) システムにおけるブラインドチャネル同定手法として Cross-Relation (CR) 法が知られている [1]. 本来の CR 法は, 単一の未知音源 s が異なる室内インパルス応答 (RIR) h_1, h_2 を経て 2 つのマイクで観測される設定に基づき, 畳み込みの可換性から導かれる関係式 $x_1 * h_2 - x_2 * h_1 = 0$ を用いて未知音源 s を代数的に消去し, RIR の組を直接同定する.

これに対し本研究では, 単一チャネル設定において未知音源と RIR の数学的役割を反転させ, CR 法をクリーン信号の直接抽出へと応用する. その概念図を図 1 に示す. 単一のマイクで異なる区間に録音された 2 つの残響信号 $x_1 \in \mathbb{R}^{n_1}, x_2 \in \mathbb{R}^{n_2}$ は, 共通の RIR $h \in \mathbb{R}^d$ と, 互いに素な 2 つのクリーン信号 $s_1 \in \mathbb{R}^{n_1-d+1}, s_2 \in \mathbb{R}^{n_2-d+1}$ の線形畳み込みとして次式でモデル化される:

$$x_i = s_i * h \quad \text{for } i = 1, 2. \quad (1)$$

畳み込みの可換性を利用して未知変数 h を消去する:

$$x_1 * s_2 = s_1 * h * s_2 = x_2 * s_1. \quad (2)$$

すると以下の単チャネル CR 式が成立する:

$$\underbrace{\begin{bmatrix} \mathbf{M}_{n_2-d+1}(x_2) & -\mathbf{M}_{n_1-d+1}(x_1) \end{bmatrix}}_{=: \mathbf{S}_d(x_1, x_2)} \begin{bmatrix} s_1 \\ s_2 \end{bmatrix} = 0. \quad (3)$$

ここで $\mathbf{M}_p(\mathbf{a}) \in \mathbb{R}^{(p+q-1) \times p}$ は, 長さ q のベクトル $\mathbf{a}$ の畳み込み演算を表現する列数 p の Toeplitz 行列であり, これらを並べた行列 $\mathbf{S}_d(x_1, x_2) \in \mathbb{R}^{(n_1+n_2-d) \times (n_1+n_2-2d+2)}$ は d 次 Sylvester 行列と呼ばれる. s_1, s_2 の Z 変換が共通の零点を持たないと, d 次 Sylvester 行列 $\mathbf{S}_d(x_1, x_2)$ の 1 次元右零空




図 1 単チャネル Cross-Relation 法概念図

間基底を求めることで, スケール不定性を除いてクリーン信号を一意に復元可能である. しかし, 実環境の信号に対しては行列 $\mathbf{S}_d$ のサイズが巨大化し, 行列演算が実行困難な点が問題である.

3 提案法: サブバンド Cross-Relation 法

上述の問題を解決するため, 提案法では時間周波数 (TF) 領域におけるサブバンド畳み込みモデルに基づく定式化を採用する. すなわち, 観測信号の短時間フーリエ変換のうち, f 番目の周波数ビンを取り出した $\tilde{x}_1^f \in \mathbb{C}^{N_1}, \tilde{x}_2^f \in \mathbb{C}^{N_2}$ を以下でモデル化する [1]:

$$\tilde{x}_i^f = \tilde{s}_i^f * \tilde{h}^f, \quad \text{for } i = 1, 2. \quad (4)$$

ここで, $\tilde{h}^f \in \mathbb{C}^D$ は時間フレーム方向に作用するサブバンドインパルス応答, $\tilde{s}_1^f \in \mathbb{C}^{N_1-D+1}, \tilde{s}_2^f \in \mathbb{C}^{N_2-D+1}$ はクリーン音のサブバンドベクトルを表す. 各周波数ビンごと独立に $\tilde{s}_1^f, \tilde{s}_2^f$ を推定し, それぞれ逆短時間フーリエ変換によって時間領域へと書き戻すことで, 目的信号を復元する. 以降, 周波数ビンを示す添字 f の表記を省略する.

式 (4) に基づき, 第 2 節での時間領域での議論と同様に $\tilde{h}$ を消去することにより, 以下の方程式を得る:

$$\underbrace{\begin{bmatrix} \mathbf{M}_{N_1-D+1}(\tilde{x}_2) & -\mathbf{M}_{N_2-D+1}(\tilde{x}_1) \end{bmatrix}}_{=: \mathbf{S}_D} \underbrace{\begin{bmatrix} \tilde{s}_1 \\ \tilde{s}_2 \end{bmatrix}}_{=: \tilde{s}} = 0. \quad (5)$$

ここで $\mathbf{S}_D \in \mathbb{C}^{(N_1+N_2-D) \times (N_1+N_2-2D+2)}$ は観測音のサブバンドベクトルから構成される Sylvester 行列であり, $\tilde{s}$ は復元対象の信号を連結したベクトルである. 短時間フーリエ変換のシフト長を L とすると, TF 領域における信号の時間フレーム数 N_1, N_2 および RIR の長さ D は, 時間領域の長さに対して約 $1/L$ に縮小される. これに伴い, 各周波数ビンで構成される Sylvester 行列 $\mathbf{S}_D$ のサイズは時間領域の $\mathbf{S}_d$ に比

*Single-Channel Blind Dereverberation based on Cross-Relation Method in Time-Frequency Representation. By Natsuki YOSHINO and Kohei YATABE (Tokyo University of Agriculture and Technology)

Algorithm 1 Sub-band Monoaural CR Method

Input: Subband signals $\tilde{x}_1 \in \mathbb{C}^{N_1}, \tilde{x}_2 \in \mathbb{C}^{N_2}$ at a certain frequency bin, prescribed RIR length D

Output: $\hat{s}_1 \in \mathbb{C}^{N_1-D+1}, \hat{s}_2 \in \mathbb{C}^{N_2-D+1}$

- 1: $\mathbf{S} \leftarrow [\mathbf{M}_{N_1-D+1}(\tilde{x}_2) \quad -\mathbf{M}_{N_2-D+1}(\tilde{x}_1)]$
- 2: $[\mathbf{U}, \mathbf{\Sigma}, \mathbf{V}] \leftarrow \text{svd}(\mathbf{S})$ ▷ Economical SVD
- 3: $\mathbf{v} \leftarrow \mathbf{V}[:, \text{end}]$
- 4: $\mathbf{v} \leftarrow \frac{\sqrt{\|\tilde{x}_1\|_2^2 + \|\tilde{x}_2\|_2^2}}{\|\mathbf{v}\|} \cdot \mathbf{v}$ ▷ Scale recovery
- 5: $[\hat{s}_1^H \hat{s}_2^H] \leftarrow \mathbf{v}^H$ ▷ Split into two signals

べて圧縮され、一般的な計算環境でも行列演算が実行可能となる。

実際には、スペクトルのもれの影響により式 (5) は厳密な解を持たない。そのため、 $\mathbf{S}_D$ の SVD $\mathbf{S}_D = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^H$ を計算し、最小特異値に対応する右特異ベクトルにより $\mathbf{S}_D$ の右零空間の基底ベクトルを代替する。各周波数ビンに対する提案法の手続きを Algorithm 1 に示す。ただし、 $\mathbf{\Sigma}$ は特異値が降順に配置された対角行列であり、 $\mathbf{V}[:, \text{end}]$ は $\mathbf{V}$ の最終列を表す。

4 数値例

提案法の有効性を検証するため、楽器音の残響除去実験を行った。クリーン信号には MIDI 音源から生成した 10 種類の異なる楽器音ペア（信号長 2 秒、サンプリング周波数 11 kHz）を使用した。各信号に対して実際の様々な室内音響環境（浴室、会議室等）においてサンプリング周波数 44.1 kHz で実測された RIR を、11 kHz にダウンサンプリングして畳み込んだ後、信号対雑音比が 20 dB となるように加法的白色ガウス雑音を重畳して観測信号を生成した。RIR には、評価用に残響時間 (RT_{60}) がそれぞれ 0.3 s, 1.0 s, 1.9 s, 2.3 s の 4 種類を用いた。短時間フーリエ変換のパラメータは、窓長を 512 サンプル、シフト長を 128 サンプルとした。TF 領域での単チャネルブラインド残響除去法である Lifting 法 [2]、および WPE 法 [3] の 2 手法を比較対象とした。残響除去性能の評価指標には、SDR の改善量である ΔSDR を用いた。

図 2 に残響時間ごとの各手法における ΔSDR の箱ひげ図を示す。実験の結果、比較的短い残響環境 ($\text{RT}_{60} = 0.3\text{s}, 1.0\text{s}$) においては各手法間で残響除去性能に大きな有意差は見られなかったが、長大残響環境へと移行するにつれ、Lifting 法および WPE 法は残響成分を十分に抑制できず、 ΔSDR が著しく低下した。一方で、提案法 (Proposed) は長大残響下 ($\text{RT}_{60} = 2.3\text{s}$) においても高い除去性能を達成した。

また、表 1 に 1 ペアあたりの平均計算時間を示す。WPE 法および Lifting 法は、残響時間の伸長に伴っ




図 2 各残響時間での残響除去性能 (ΔSDR) の比較

表 1 異なる残響時間にわたる平均計算時間 (s)

RT ₆₀	0.3 s	1.0 s	1.8 s	2.3 s
Proposed	7.46	7.75	9.34	10.06
Lifting	54.10	193.77	492.38	625.02
WPE	0.46	0.93	4.29	5.12

て計算コストが爆発的に増加しており、特に Lifting 法では $\text{RT}_{60} = 2.3\text{s}$ において 10 分を超える膨大な計算時間を要した。一方、提案法は最適化を要しない単純な解法であるため、残響時間が 0.3 s から 2.3 s へと激化した場合でも、実行時間は約 7 s から 10 s の範囲に留まり、ほぼ一定の計算コストを維持した。以上の結果から、提案法は長大残響環境において、優れた残響除去性能と低い計算コストを両立することが確認された。

5 結び

単チャネル設定下の CR 法に基づくブラインド残響除去を TF 領域で定式化することで、空間計算量の増大問題を効果的に解決する手法を提案し、評価実験によりその有効性を確認した。今後は、周波数ビン間での位相の不整合問題の解決に取り組む。

謝辞 本研究は、科学技術振興機構 (JST) 創発的研究支援事業 (JPMJFR2330) の支援を受けて実施されたものである。

参考文献

- [1] X. Li, S. Gannot, L. Girin and R. Horaud, "Multi-channel Identification and Nonnegative Equalization for Dereverberation and Noise Reduction Based on Convolutional Transfer Function," in IEEE/ACM TASLP, **26**(10), pp.1755-1768, Oct. 2018
- [2] F. Yohena and K. Yatabe, "Single-channel blind dereverberation based on sparse matrix recovery with reweighting and accelerated alternating direction method of multipliers," Acoust. Sci. & Tech., **46**(5), pp.544-552, Sep. 2025.
- [3] R. Ikeshita, N. Kamo, and T. Nakatani, "Blind signal dereverberation based on mixture of weighted prediction error models," IEEE Signal Process. Lett., **28**, pp. 399-403, 2021.