

単チャネル Cross-Relation 法に基づく時間周波数領域ブラインド残響除去*

©吉野夏樹, 矢田部浩平 (農工大)

概要

複数マイクの信号から残響特性を求める Cross-Relation 法に着目する．音源と残響の数学的な関係性を反転させ単一チャネルへ応用し，音源の情報に依存せずに残響を除去する手法を提案する．(94 letters)

keywords: ブラインド残響除去, 単一チャネル, Cross-Relation 法, 時間周波数解析

1 はじめに

音響信号処理の多くの実用例において，マイクロホンを通じて観測される信号には，残響を含まない目的の直接音だけでなく，録音環境に依存した残響成分が含まれる．残響は自動音声認識システムの性能を低下させることが知られており，また音楽制作の分野においては，直接音信号はその明瞭性や後処理における柔軟性の高さから極めて重視される．したがって，録音環境に関する事前情報が利用できない状況下（ブラインド）での残響除去は，音響信号処理における重要な最優先課題でありながら，困難な問題として位置づけられてきた．

近年，線形予測残差法（Weighted Prediction Error, WPE）や空間的な冗長性に基づいて単一の音源から複数の音響伝達関数を同定する Cross-Relation (CR) 法を活用することで，複数マイクロホンでの録音環境における残響除去が進展している．しかし，それらの手法は複数マイクロホン構成を必要とし，さらに人間の音声の非定常性といった，音源に対する統計的の仮定に依存することが多い．その結果，根本的に異なる音響特性を示す楽器音などの非音声信号へ汎化させることは困難であった．さらに，残響時間が長大な環境において，時間領域でブラインドシステム同定を実行しようとする，残響モデルに由来する方程式のサイズが膨大になり，標準的なメモリ容量を容易に超過するという空間計算量の問題も存在していた．

これらの限界を克服するため，本研究では，単チャネル設定下における CR 法と双対な定式化に基づく，新しいブラインド残響除去手法を提案する．単一の音源が複数のインパルス応答と畳み込まれる状況を想定する従来の CR 法とは異なり，本アプローチでは，単チャネル観測信号から切り出された複数の異なる音源信号の断片に対して，単一の共通するインパルス応答が畳み込まれるという双対なシナリオを仮定する．この定式化を短時間フーリエ変換（STFT）領域で実装することにより，長大残響に伴う空間計算量問題を効果的に解決する．また，音源に関する事前知識に依存することなくロバストな最適化を達成するため，本手法では，時間方向のグループスパース（ $L_{2,1}$ ）正則化を組み込んだ交互方向乗数法（Alternating Direction Method of Multipliers, ADMM）の枠組みを導入する．これにより，信号波形の過剰な抑制を回避する．数値シミュレーションを通じて提案手法の有効性を検証する．

2 Dereverberation via Deconvolution in Time-Domain

時間領域での Cross-Relation 法に基づくマルチチャネルブラインドシステム同定に書き換える．そのあと，信号とインパルス応答の役割を入れ替えても同様の議論ができることから，単チャネル設定においても同様の定式化が可能であることを示す．In room acoustic environments, the signal recorded by a microphone can be modeled as the linear convolution of the room impulse response (RIR) $\mathbf{h} \in \mathbb{R}^d$ with a dry signal that does not include reverberation:

$$\mathbf{x} = \mathbf{s} * \mathbf{h}. \quad (1)$$

*本研究は，科学技術振興機構（JST）創発的研究支援事業（JPMJFR****）の支援を受けて実施されたものである．

By introducing the convolution matrix $\mathbf{M}_l(\mathbf{a})$, the convolution can be rewritten as:

$$\mathbf{s} * \mathbf{h} = \mathbf{M}_d(\mathbf{s})\mathbf{h} = \mathbf{M}_l(\mathbf{h})\mathbf{s}$$

Dereverberation is the task that estimates $\mathbf{s}$ from $\mathbf{x}$. If we are informed about $\mathbf{h}$ in advance, it is a simple linear problem. However, in practice, the RIR is hard to know or cannot measure accurately, resulting in a bilinear difficulty of the problem. In this paper, we assume that two different signals $\mathbf{s}_1 \in \mathbb{R}^{l_1}$ and $\mathbf{s}_2 \in \mathbb{R}^{l_2}$, both convolved with the same RIR, result in:

$$\mathbf{x}_1 = \mathbf{s}_1 * \mathbf{h} \in \mathbb{R}^{n_1} \quad (2)$$

$$\mathbf{x}_2 = \mathbf{s}_2 * \mathbf{h} \in \mathbb{R}^{n_2} \quad (3)$$

Then, dereverberation can be done as:

$$\begin{aligned} \mathbf{x}_1 * \mathbf{s}^2 &= \mathbf{s}^1 * \mathbf{h} * \mathbf{s}^2 = \mathbf{x}^2 * \mathbf{s}^1 \\ \iff \mathbf{x}^1 * \mathbf{s}^2 - \mathbf{x}^2 * \mathbf{s}^1 &= \mathbf{0} \\ \iff [\mathbf{M}_{l_2}(\mathbf{x}^2) \mathbf{M}_{l_2}(\mathbf{x}^1)] \begin{bmatrix} \mathbf{s}^1 \\ -\mathbf{s}^2 \end{bmatrix} &= \mathbf{0} \end{aligned} \quad (4)$$

The matrix appearing in the last row of the above equation is known as the *d-th subresultant Sylvester matrix* $\mathbf{A}_d^{time}(\mathbf{x}^1, \mathbf{x}^2)$. If $\mathbf{s}^1$ and $\mathbf{s}^2$ are coprime—that is, they are not convolutions of the same vector—the vector that annihilates $\mathbf{A}_d^{time}$ is uniquely determined up to scalar multiplication, as shown in the above equation. Therefore, the dry signals $\mathbf{s}^1$ and $\mathbf{s}^2$ can be recovered as the right singular vector corresponding to the unique zero singular value.

about the negative aspect of Time domain deconvolution However, the Sylvester matrix is often of huge size in practical situations. For example, if the lengths of the dry signals and RIR are 1 sec 20kHz of sampling frequency, the size of Sylvester matrix is X by Y, occupying more than 16GB in double floating point accuracy. This quantity is too large for the personal computer, and users cannot run the program.

3 提案法

3.1 サブバンド畳み込みモデルに基づく定式化

時間領域において、2組の独立したクリーン音声信号を $s^1(t), s^2(t)$ とし、これらが同一の部屋インパルス応答 (RIR) $h(t)$ を経て観測信号 $x^1(t), x^2(t)$ として得られる音響システムを想定する。このとき、時間領域における観測モデルは次式のように線形畳み込み演算 $*$ を用いて表される：

$$x^1(t) = s^1(t) * h(t), \quad x^2(t) = s^2(t) * h(t) \quad (5)$$

これらの信号に対し、窓関数を用いた短時間フーリエ変換 (STFT) あるいは離散ガボール変換 (DGT) を適用し、時間周波数 (TF) 領域へ変換する。各周波数ビン f において、時間フレーム方向のサブバンド畳み込み近似が成り立つと仮定すると、TF 領域における観測信号 $X_f^1(n), X_f^2(n)$ は以下のようにモデル化できる¹：

$$X_f^1(n) \approx s_f^1(n) * h_f(n), \quad X_f^2(n) \approx s_f^2(n) * h_f(n) \quad (6)$$

ここで、 n は時間フレームのインデックスであり、 $s_f^1(n), s_f^2(n)$ はクリーン音声のサブバンド成分、 $h_f(n)$ は時間フレーム方向に作用するサブバンドインパルス応答を表す。

¹クロスバンド成分を含めた厳密な畳み込みモデルも知られている [引用:crossband filtering].

3.2 共通因子分解と Sylvester 行列の構成

続いて、式 (2) より、共通のサブバンドインパルス応答 $h_f(n)$ を消去するために、ベクトルの畳み込み演算に関する可換性 ($s_f^1 * h_f * s_f^2 = s_f^2 * h_f * s_f^1$) を利用すると、以下の関係式が導かれる：

$$X_f^1(n) * s_f^2(n) - X_f^2(n) * s_f^1(n) \approx 0 \quad (7)$$

式 (7) は、観測信号の複素スペクトル時系列から生成される Toeplitz 行列 $\mathbf{C}(X_f^1), \mathbf{C}(X_f^2)$ 、およびクリーン音声のサブバンドベクトル $\mathbf{s}_f^1, \mathbf{s}_f^2$ を用いることで、次のような線形行列方程式の形式に書き換えることができる：

$$\mathbf{C}(X_f^1)\mathbf{s}_f^2 - \mathbf{C}(X_f^2)\mathbf{s}_f^1 \approx \mathbf{0} \quad (8)$$

これらを1つの係数行列としてブロック結合により統合することで、以下に示す方程式を得る：

$$\begin{bmatrix} \mathbf{C}(X_f^2) & -\mathbf{C}(X_f^1) \end{bmatrix} \begin{bmatrix} \mathbf{s}_f^1 \\ \mathbf{s}_f^2 \end{bmatrix} \approx \mathbf{0} \quad (9)$$

ここで、左辺の係数行列は以下のように定義される Sylvester 行列 $\mathbf{A}_f$ に相当する：

$$\mathbf{A}_f \stackrel{\text{def}}{=} \begin{bmatrix} \mathbf{C}(X_f^2) & -\mathbf{C}(X_f^1) \end{bmatrix} \quad (10)$$

3.3 最小特異値に対応する特異ベクトルによる近似解法

理想的な線形畳み込み条件、かつ信号長が十分である無雑音下においては、クリーン信号ベクトル $\mathbf{u}_f = [\mathbf{s}_f^{1H}, \mathbf{s}_f^{2H}]^H$ は Sylvester 行列 $\mathbf{A}_f$ の右零空間の基底ベクトルとして一意に獲得できる。

しかしながら、TF 領域での畳み込みモデルはあくまで近似であり、雑音が存在しない理想的な状況においてもスペクトルのもれなどの影響により、式 (9) は厳密な解を持たない。加えて、実際の環境では雑音は不可避免的に混入するために $\mathbf{A}_f$ はフルランク行列となってしまう、やはり厳密な意味での零空間は存在しない。

そこで本手法では、等式拘束 $\mathbf{A}_f \mathbf{u}_f = \mathbf{0}$ を最小二乗の意味で近似的に解くため、特異値分解 (SVD) を利用する。 $\mathbf{A}_f$ の SVD を $\mathbf{A}_f = \mathbf{U}_f \mathbf{\Sigma}_f \mathbf{V}_f^H$ としたとき、最小特異値に対応する右特異ベクトル $\mathbf{v}_{f,\min}$ (すなわち $\mathbf{V}_f$ の最終列ベクトル) をクリーン信号の推定解 $\hat{\mathbf{u}}_f$ として採用する：

$$\hat{\mathbf{u}}_f = \mathbf{v}_{f,\min} \quad (11)$$

3.4 提案法： L_{21} 正則化 ADMM によるアルゴリズムの高度化

前節で述べた SVD に基づく最小特異ベクトルの抽出 (式 (7)) は、無雑音かつ理想的なサブバンド畳み込み条件下においては有効な解を与える。しかしながら、実環境における観測信号には環境雑音が含まれるだけでなく、音声信号の無音区間に対して非因果的な音漏れが生じ、分離音声の品質を著しく劣化させるという課題がある。

この課題に対処するため、本研究では、時間領域における発音区間と無音区間の連続性に着目し、時間フレームの近傍ブロック単位でエネルギーを収縮させる **グループスパース ($L_{2,1}$) 正則化**を導入する。これにより、等式拘束 $\mathbf{S}_f \mathbf{u}_f \approx \mathbf{0}$ を緩やかに満たしつつ、不要な音漏れ成分のみを排他的にゼロに潰すアルゴリズムへと拡張する。

グループスパース性を導入した定式化 ある周波数ビン f において、未知の元信号ベクトル (2つの信号の STFT 成分を縦に連結したもの) を $\mathbf{u} \in \mathbb{C}^{2T}$ 、観測信号から構成した Sylvester 行列を $\mathbf{A} \in \mathbb{C}^{M \times 2T}$ とする。モデルの等式拘束 $\mathbf{A}\mathbf{u} \approx \mathbf{0}$ を満たしつつ、時間的な無音区間の音漏れを防ぐために時間フレームの近傍ブロックごとにグループスパース性を誘導する。

全体の最適化問題は以下のように定式化される。

$$\min_{\mathbf{u}, \mathbf{z}} \frac{1}{2} \|\mathbf{A}\mathbf{u}\|_2^2 + \alpha \|\mathbf{z}\|_{2,1} \quad \text{subject to } \mathbf{u} = \mathbf{z}$$

ここで, $\|\mathbf{z}\|_{2,1}$ は $L_{2,1}$ 混合ノルムであり, ベクトルを $G = |\mathcal{G}|$ 個の互いに素なグループ $\mathcal{G} = \{\mathbf{g}_1, \mathbf{g}_2, \dots, \mathbf{g}_G\}$ に時間方向の分割したとき, 以下のように定義される.

$$\|\mathbf{z}\|_{2,1} = \sum_{g=1}^G \|\mathbf{z}_{\mathbf{g}_g}\|_2$$

各グループ $\mathbf{g}_i$ 内の L_2 ノルムの和を取ることで, グループ単位でのスパース性を促す.

拡張ラグランジュ関数の構成 ADMM を適用するため, 拡張ラグランジュ関数を構成し, 平方完成する:

$$\begin{aligned} \mathcal{L}_\rho(\mathbf{u}, \mathbf{z}, \mathbf{y}) &= \frac{1}{2} \|\mathbf{A}\mathbf{u}\|_2^2 + \alpha \sum_{g=1}^G \|\mathbf{z}_{\mathbf{g}_g}\|_2 + \text{Re}\langle \mathbf{y}, \mathbf{u} - \mathbf{z} \rangle + \frac{\rho}{2} \|\mathbf{u} - \mathbf{z}\|_2^2 \\ &= \frac{1}{2} \|\mathbf{A}\mathbf{u}\|_2^2 + \alpha \sum_{g=1}^G \|\mathbf{z}_{\mathbf{g}_g}\|_2 + \frac{\rho}{2} \left\| \mathbf{u} - \mathbf{z} + \frac{\mathbf{y}}{\rho} \right\|_2^2 - \frac{1}{2\rho} \|\mathbf{y}\|_2^2. \end{aligned} \quad (12)$$

ここで $\mathbf{y} \in \mathbb{C}^{2T}$ は等式拘束 $\mathbf{u} = \mathbf{z}$ に対するラグランジュ乗数, $\rho > 0$ はペナルティパラメータである.

ADMM による反復更新則の導出

Step 1 $\mathbf{z}$ と $\mathbf{y}$ を固定し, $\mathcal{L}_\rho$ を $\mathbf{u}$ について最小化する.

$$\mathbf{u}^{(k+1)} = \arg \min_{\mathbf{u}} \frac{1}{2} \|\mathbf{A}\mathbf{u}\|_2^2 + \frac{\rho}{2} \left\| \mathbf{u} - \mathbf{z}^{(k)} + \frac{\mathbf{y}^{(k)}}{\rho} \right\|_2^2 \quad (13)$$

この $\mathbf{u}^*$ に関する勾配が 0 になる点を求めることで, 更新式を得る²:

$$\begin{aligned} \mathbf{A}^H \mathbf{A} \mathbf{u} + \rho \left(\mathbf{u}^{(k+1)} - \mathbf{z}^{(k)} + \frac{\mathbf{y}^{(k)}}{\rho} \right) &= \mathbf{0} \\ \Leftrightarrow \mathbf{u}^{(k+1)} &= (\mathbf{A}^H \mathbf{A} + \rho \mathbf{I})^{-1} (\rho \mathbf{z}^{(k)} - \mathbf{y}^{(k)}). \end{aligned} \quad (14)$$

Step 2 $\mathbf{u}$ と $\mathbf{y}$ を固定し, $\mathcal{L}_\rho$ を $\mathbf{z}$ について最小化する.

$$\mathbf{z}^{(k+1)} = \arg \min_{\mathbf{z}} \alpha \sum_{g=1}^G \|\mathbf{z}_{\mathbf{g}_g}\|_2 + \frac{\rho}{2} \left\| \mathbf{u}^{(k+1)} - \mathbf{z} + \frac{\mathbf{y}^{(k)}}{\rho} \right\|_2^2 \quad (15)$$

この問題は, 各グループ $\mathbf{g}_g$ ごとに完全に独立した問題に分解可能である. $\mathbf{v} = \mathbf{u}^{(k+1)} + \frac{1}{\rho} \mathbf{y}^{(k)}$ と置くことで各グループの最適化問題は次式で表される.

$$\mathbf{z}_{\mathbf{g}_g}^{(k+1)} = \arg \min_{\mathbf{z}_{\mathbf{g}_g}} \alpha \|\mathbf{z}_{\mathbf{g}_g}\|_2 + \frac{\rho}{2} \|\mathbf{z}_{\mathbf{g}_g} - \mathbf{v}_{\mathbf{g}_g}\|_2^2 \quad (16)$$

これは Block Soft-Thresholding の定義そのものであり, 解析的に以下の解が得られる.

$$\mathbf{z}_{\mathbf{g}_g}^{(k+1)} = \text{prox}_{\frac{\alpha}{\rho} \|\cdot\|_2}(\mathbf{v}_{\mathbf{g}_g}) \quad (17)$$

$$= \max \left(1 - \frac{\alpha}{\rho \|\mathbf{v}_{\mathbf{g}_g}\|_2}, 0 \right) \mathbf{v}_{\mathbf{g}_g} \quad (18)$$

² グループスパース性を導入しないナイーブなアルゴリズムは, 雑音に対して非常に脆弱であった. そのため以前の実装では Tikonov 正則化を導入したのだが, 現在導出しているアルゴリズムでは, $\rho \mathbf{I}$ の加算が同様の役割を果たしている.

Step 3 最後に、等式拘束の残差を用いてラグランジュ乗数を更新する.

$$\mathbf{y}^{(k+1)} = \mathbf{y}^{(k)} + \rho \left(\mathbf{u}^{(k+1)} - \mathbf{z}^{(k+1)} \right) \quad (19)$$

Step 4: スケール拘束 (非凸) への対処 この問題は本質的に、零空間の探索 (= システム同定) であるため、 $\mathbf{u} = \mathbf{0}$ という自明な解に潰れるのを防ぐ必要がある. 元のモデルでは $\|\mathbf{u}\|_2 = 1$ という球面拘束があるものの、これは non-convex 拘束である. 本稿では ADMM の標準的な収束性を崩さないため、「ADMM の 1 ループの終わりに、スパース化された解 $\mathbf{z}$ を射影する」というアプローチを取る.

$$\mathbf{z}^{(k+1)} \leftarrow \frac{\mathbf{z}^{(k+1)}}{\|\mathbf{z}^{(k+1)}\|_2} \quad (20)$$

これにより、自明解をさけながら不要な音漏れだけを排除することを目指す.

4 数値シミュレーション

4.1 シミュレーションの設定

シミュレーションでは、クリーン信号は MIDI 音源から生成された楽器音であり、RIR は実測されたものを使用する. 観測信号はこれらのクリーン信号と RIR の畳み込みにより生成される. 提案法の性能は、クリーン信号と推定された信号の SDR を評価することで評価する. サンプル周波数は 12kHz, STFT のフレーム長は 512 サンプル, ホップサイズは 128 サンプルである. グループスパース正則化の強度を制御するハイパーパラメータ α は経験的に 0.01 を選択した.

4.2 結果

持続する音に対しても、提案法はクリーン信号と比較して高い SDR を達成し、従来の L1 正則化のアプローチと比較して過度に抑制されないことが示された. 以下にスペクトログラムを示す.

5 結論

本研究では、単チャネル設定におけるブラインド残響除去のための新しい手法を提案した. 時間周波数領域でのサブバンド畳み込みモデルに基づく定式化と、グループスパース正則化を組み込んだ ADMM アルゴリズムの導入により、長大残響環境下での空間計算量問題を解決しつつ、信号波形の過剰な抑制を回避した. 数値シミュレーションにおいて、提案法はクリーン信号と比較して高い SDR を達成し、従来の SVD ベースのアプローチと比較して雑音耐性が向上することが示された. 今後の研究では、実録音データへの適用を検討する予定である.




Fig. 1 ドライ音のスペクトログラム




Fig. 2 残響時間 2.6 秒の観測音のスペクトログラム (SDR=-0.70 dB)




Fig. 3 復元音のスペクトログラム (SDR=9.06 dB)




Fig. 4 ドライ音のスペクトログラム




Fig. 5 残響時間 2.6 秒の観測音のスペクトログラム (SDR=-2.08 dB)




Fig. 6 復元音のスペクトログラム (SDR=7.17 dB)