

1 はじめに

In many practical scenarios of audio signal processing, signals recorded via microphones contain not only the target dry sound—free from reverberation—but also reverberation components that depend on the recording environment. Reverberation is known to degrade the performance of automatic speech recognition systems, and in music production, dry signals are highly valued for their clarity and flexibility in post-processing. Consequently, dereverberation has become a critical topic in acoustic signal processing.

Among various approaches, blind dereverberation—where no prior information about the recording environment is available—remains a particularly challenging and important problem. Recent studies have made progress by restricting the target signal to human speech, thereby allowing the use of prior knowledge about the source characteristics. However, such methods often fail to generalize well to non-speech signals, such as musical instrument sounds, which exhibit fundamentally different acoustic properties. Multichannel microphone setups have also been explored, leveraging spatial information to achieve effective dereverberation. While these approaches have shown promising results, single-channel dereverberation still presents significant limitations and room for improvement.

In this study, we address the problem of blind dereverberation under a single-channel setting, without making assumptions about the source signal. Our goal is to develop a method that generalizes across diverse signal types and operates effectively without relying on environmental or source-specific priors

2 Dereverberation via Deconvolution in Time-Domain

In room acoustic environments, the signal recorded by a microphone can be modeled as the linear convolution of the room impulse response (RIR) $\mathbf{h} \in \mathbb{R}^d$ with a dry signal that does not include reverberation:

$$\mathbf{x} = \mathbf{s} * \mathbf{h}. \quad (1)$$

By introducing the convolution matrix $\mathbf{M}_l(\mathbf{a})$, the convolution can be rewritten as:

$$\mathbf{s} * \mathbf{h} = \mathbf{M}_d(\mathbf{s})\mathbf{h} = \mathbf{M}_l(\mathbf{h})\mathbf{s}$$

Dereverberation is the task that estimates $\mathbf{s}$ from $\mathbf{x}$. If we are informed about $\mathbf{h}$ in advance, it is a simple linear problem. However, in practice, the RIR is hard to know or cannot measure accurately, resulting in a bilinear difficulty of the problem. In this paper, we assume that two different signals $\mathbf{s}_1 \in \mathbb{R}^{l_1}$ and $\mathbf{s}_2 \in \mathbb{R}^{l_2}$, both convolved with the same RIR, result in:

$$\mathbf{x}_1 = \mathbf{s}_1 * \mathbf{h} \in \mathbb{R}^{n_1} \quad (2)$$

$$\mathbf{x}_2 = \mathbf{s}_2 * \mathbf{h} \in \mathbb{R}^{n_2} \quad (3)$$

Then, dereverberation can be done as:

$$\begin{aligned} \mathbf{x}_1 * \mathbf{s}^2 &= \mathbf{s}^1 * \mathbf{h} * \mathbf{s}^2 = \mathbf{x}^2 * \mathbf{s}^1 \\ \iff \mathbf{x}^1 * \mathbf{s}^2 - \mathbf{x}^2 * \mathbf{s}^1 &= \mathbf{0} \\ \iff [\mathbf{M}_{l_2}(\mathbf{x}^2) \mathbf{M}_{l_2}(\mathbf{x}^1)] \begin{bmatrix} \mathbf{s}^1 \\ -\mathbf{s}^2 \end{bmatrix} &= \mathbf{0} \end{aligned} \quad (4)$$

The matrix appearing in the last row of the above equation is known as the d -th *subresultant Sylvester matrix* $\mathbf{A}_d^{time}(\mathbf{x}^1, \mathbf{x}^2)$. If $\mathbf{s}^1$ and $\mathbf{s}^2$ are coprime—that is, they are not convolutions of the same vector—the vector that annihilates $\mathbf{A}_d^{time}$ is uniquely determined up to scalar multiplication, as shown in the above equation. Therefore, the dry signals $\mathbf{s}^1$ and $\mathbf{s}^2$ can be recovered as the right singular vector corresponding to the unique zero singular value.

about the negative aspect of Time domain deconvolution However, the Sylvester matrix is often of huge size in practical situations. For example, if the lengths of the dry signals and RIR are 1 sec 20kHz of sampling frequency, the size of Sylvester matrix is X by Y , occupying more than 16GB in double floating point accuracy. This quantity is too large for the personal computer, and users cannot run the program.

3 提案法

3.1 サブバンド畳み込みモデルに基づく定式化

時間領域において、2組の独立したクリーン音声信号を $s^1(t), s^2(t)$ とし、これらが同一の部屋インパルス応答 (RIR) $h(t)$ を経て観測信号 $x^1(t), x^2(t)$ として得られる音響システムを想定する。このとき、時間領域における観測モデルは次式のように線形畳み込み演算 $*$ を用いて表される：

$$x^1(t) = s^1(t) * h(t), \quad x^2(t) = s^2(t) * h(t) \quad (5)$$

これらの信号に対し、窓関数を用いた短時間フーリエ変換 (STFT) あるいは離散ガボール変換 (DGT) を適用し、時間周波数 (TF) 領域へ変換する。各周波数ビン f において、時間フレーム方向のサブバンド畳み込み近似が成り立つと仮定すると、TF 領域における観測信号 $X_f^1(n), X_f^2(n)$ は以下のようにモデル化できる¹：

$$X_f^1(n) \approx s_f^1(n) * h_f(n), \quad X_f^2(n) \approx s_f^2(n) * h_f(n) \quad (6)$$

ここで、 n は時間フレームのインデックスであり、 $s_f^1(n), s_f^2(n)$ はクリーン音声のサブバンド成分、 $h_f(n)$ は時間フレーム方向に作用するサブバンドインパルス応答を表す。

3.2 共通因子分解と Sylvester 行列の構成

続いて、式 (2) より、共通のサブバンドインパルス応答 $h_f(n)$ を消去するために、ベクトルの畳み込み演算に関する可換性 ($s_f^1 * h_f * s_f^2 = s_f^2 * h_f * s_f^1$) を利用すると、以下の関係式が導かれる：

$$X_f^1(n) * s_f^2(n) - X_f^2(n) * s_f^1(n) \approx 0 \quad (7)$$

¹クロスバンド成分を含めた厳密な畳み込みモデルも知られている [引用:crossband filtering].

式 (7) は、観測信号の複素スペクトル時系列から生成される Toeplitz 行列 $\mathbf{C}(X_f^1), \mathbf{C}(X_f^2)$ 、およびクリーン音声のサブバンドベクトル $\mathbf{s}_f^1, \mathbf{s}_f^2$ を用いることで、次のような線形行列方程式の形式に書き換えることができる：

$$\mathbf{C}(X_f^1)\mathbf{s}_f^2 - \mathbf{C}(X_f^2)\mathbf{s}_f^1 \approx \mathbf{0} \quad (8)$$

これらを1つの係数行列としてブロック結合により統合することで、以下に示す方程式を得る：

$$\begin{bmatrix} \mathbf{C}(X_f^2) & -\mathbf{C}(X_f^1) \end{bmatrix} \begin{bmatrix} \mathbf{s}_f^1 \\ \mathbf{s}_f^2 \end{bmatrix} \approx \mathbf{0} \quad (9)$$

ここで、左辺の係数行列は以下のように定義される Sylvester 行列 $\mathbf{A}_f$ に相当する：

$$\mathbf{A}_f \stackrel{\text{def}}{=} \begin{bmatrix} \mathbf{C}(X_f^2) & -\mathbf{C}(X_f^1) \end{bmatrix} \quad (10)$$

3.3 最小特異値に対応する特異ベクトルによる近似解法

理想的な線形畳み込み条件、かつ信号長が十分である無雑音下においては、クリーン信号ベクトル $\mathbf{u}_f = [\mathbf{s}_f^1, \mathbf{s}_f^2]^T$ は Sylvester 行列 $\mathbf{A}_f$ の右零空間の基底ベクトルとして一意に獲得できる。

しかしながら、TF 領域での畳み込みモデルはあくまで近似であり、雑音が存在しない理想的な状況においてもスペクトルのもれなどの影響により、式 (9) は厳密な解を持たない。加えて、実際の環境では雑音は不可避免的に混入するために $\mathbf{A}_f$ はフルランク行列となってしまう、やはり厳密な意味での零空間は存在しない。

そこで本手法では、等式拘束 $\mathbf{A}_f \mathbf{u}_f = \mathbf{0}$ を最小二乗の意味で近似的に解くため、特異値分解 (SVD) を利用する。 $\mathbf{A}_f$ の SVD を $\mathbf{A}_f = \mathbf{U}_f \mathbf{\Sigma}_f \mathbf{V}_f^H$ としたとき、最小特異値に対応する右特異ベクトル $\mathbf{v}_{f,\min}$ (すなわち $\mathbf{V}_f$ の最終列ベクトル) をクリーン信号の推定解 $\hat{\mathbf{u}}_f$ として採用する：

$$\hat{\mathbf{u}}_f = \mathbf{v}_{f,\min} \quad (11)$$

3.4 提案法： L_{21} 正則化 ADMM によるアルゴリズムの高度化

前節で述べた SVD に基づく最小特異ベクトルの抽出 (式 (7)) は、無雑音かつ理想的なサブバンド畳み込み条件下においては有効な解を与える。しかしながら、実環境における観測信号には環境雑音が含まれるだけでなく、音声信号の無音区間に対して非因果的な音漏れが生じ、分離音声の品質を著しく劣化させるという課題がある。

この課題に対処するため、本研究では、時間領域における発音区間と無音区間の連続性に着目し、時間フレームの近傍ブロック単位でエネルギーを収縮させるグループスパース ($L_{2,1}$) 正則化を導入する。これにより、等式拘束 $\mathbf{S}_f \mathbf{u}_f \approx \mathbf{0}$ を緩やかに満たしつつ、不要な音漏れ成分のみを排他的にゼロに潰すアルゴリズムへと拡張する。

グループスパース性を導入した定式化 ある周波数ビン f において、未知の元信号ベクトル (2つの信号の STFT 成分を縦に連結したもの) を $\mathbf{u} \in \mathbb{C}^{2T}$, 観測信号から構成した Sylvester 行列を $\mathbf{A} \in \mathbb{C}^{M \times 2T}$ とする。モデルの等式拘束 $\mathbf{A}\mathbf{u} \approx \mathbf{0}$ を満たしつつ、時間的な無音区間の音漏れを防ぐために時間フレームの近傍ブロックごとにグループスパース性を誘導する。

全体の最適化問題は以下のように定式化される。

$$\min_{\mathbf{u}, \mathbf{z}} \frac{1}{2} \|\mathbf{A}\mathbf{u}\|_2^2 + \alpha \|\mathbf{z}\|_{2,1} \quad \text{subject to } \mathbf{u} = \mathbf{z}$$

ここで、 $\|\mathbf{z}\|_{2,1}$ は $L_{2,1}$ 混合ノルムであり、ベクトルを $G = |\mathcal{G}|$ 個の互いに素なグループ $\mathcal{G} = \{\mathbf{g}_1, \mathbf{g}_2, \dots, \mathbf{g}_G\}$ に時間方向の分割したとき、以下のように定義される。

$$\|\mathbf{z}\|_{2,1} = \sum_{g=1}^G \|\mathbf{z}_{\mathbf{g}_g}\|_2$$

各グループ $\mathbf{g}_i$ 内の L_2 ノルムの和を取ることで、グループ単位でのスパース性を促す。

拡張ラグランジュ関数の構成 ADMM を適用するため、拡張ラグランジュ関数を構成し、平方完成する：

$$\begin{aligned} \mathcal{L}_\rho(\mathbf{u}, \mathbf{z}, \mathbf{y}) &= \frac{1}{2} \|\mathbf{A}\mathbf{u}\|_2^2 + \alpha \sum_{g=1}^G \|\mathbf{z}_{\mathbf{g}_g}\|_2 \\ &\quad + \text{Re}\langle \mathbf{y}, \mathbf{u} - \mathbf{z} \rangle + \frac{\rho}{2} \|\mathbf{u} - \mathbf{z}\|_2^2 \\ &= \frac{1}{2} \|\mathbf{A}\mathbf{u}\|_2^2 + \alpha \sum_{g=1}^G \|\mathbf{z}_{\mathbf{g}_g}\|_2 \\ &\quad + \frac{\rho}{2} \left\| \mathbf{u} - \mathbf{z} + \frac{\mathbf{y}}{\rho} \right\|_2^2 - \frac{1}{2\rho} \|\mathbf{y}\|_2^2. \end{aligned} \quad (12)$$

ここで $\mathbf{y} \in \mathbb{C}^{2T}$ は等式拘束 $\mathbf{u} = \mathbf{z}$ に対するラグランジュ乗数、 $\rho > 0$ はペナルティパラメータである。

ADMM による反復更新則の導出

Step 1 $\mathbf{z}$ と $\mathbf{y}$ を固定し、 $\mathcal{L}_\rho$ を $\mathbf{u}$ について最小化する。

$$\mathbf{u}^{(k+1)} = \arg \min_{\mathbf{u}} \frac{1}{2} \|\mathbf{A}\mathbf{u}\|_2^2 + \frac{\rho}{2} \left\| \mathbf{u} - \mathbf{z}^{(k)} + \frac{\mathbf{y}^{(k)}}{\rho} \right\|_2^2 \quad (13)$$

この $\mathbf{u}^*$ に関する勾配が 0 になる点を求めることで、更新式を得る²：

$$\begin{aligned} \mathbf{A}^H \mathbf{A} \mathbf{u} + \rho \left(\mathbf{u}^{(k+1)} - \mathbf{z}^{(k)} + \frac{\mathbf{y}^{(k)}}{\rho} \right) &= \mathbf{0} \\ \Leftrightarrow \mathbf{u}^{(k+1)} &= (\mathbf{A}^H \mathbf{A} + \rho \mathbf{I})^{-1} (\rho \mathbf{z}^{(k)} - \mathbf{y}^{(k)}). \end{aligned} \quad (14)$$

Step 2 $\mathbf{u}$ と $\mathbf{y}$ を固定し、 $\mathcal{L}_\rho$ を $\mathbf{z}$ について最小化する。

$$\mathbf{z}^{(k+1)} = \arg \min_{\mathbf{z}} \alpha \sum_{g=1}^G \|\mathbf{z}_{\mathbf{g}_g}\|_2 + \frac{\rho}{2} \left\| \mathbf{u}^{(k+1)} - \mathbf{z} + \frac{\mathbf{y}^{(k)}}{\rho} \right\|_2^2 \quad (15)$$

この問題は、各グループ $\mathbf{g}_g$ ごとに完全に独立した問題に分解可能である。 $\mathbf{v} = \mathbf{u}^{(k+1)} + \frac{1}{\rho} \mathbf{y}^{(k)}$ と置くことで各グループの最適化問題は次式で表される。

$$\mathbf{z}_{\mathbf{g}_g}^{(k+1)} = \arg \min_{\mathbf{z}_{\mathbf{g}_g}} \alpha \|\mathbf{z}_{\mathbf{g}_g}\|_2 + \frac{\rho}{2} \|\mathbf{z}_{\mathbf{g}_g} - \mathbf{v}_{\mathbf{g}_g}\|_2^2 \quad (16)$$

これは Block Soft-Thresholding の定義そのものであり、解析的に以下の解が得られる。

$$\mathbf{z}_{\mathbf{g}_g}^{(k+1)} = \text{prox}_{\frac{\alpha}{\rho} \|\cdot\|_2}(\mathbf{v}_{\mathbf{g}_g}) = \max \left(1 - \frac{\alpha}{\rho \|\mathbf{v}_{\mathbf{g}_g}\|_2}, 0 \right) \mathbf{v}_{\mathbf{g}_g} \quad (17)$$

Step 3 最後に、等式拘束の残差を用いてラグランジュ乗数を更新する。

$$\mathbf{y}^{(k+1)} = \mathbf{y}^{(k)} + \rho (\mathbf{u}^{(k+1)} - \mathbf{z}^{(k+1)})$$

² グループスパース性を導入しないナイーブなアルゴリズムは、雑音に対して非常に脆弱であった。そのため以前の実装では Tikonov 正則化を導入したのだが、現在導出しているアルゴリズムでは、 $\rho \mathbf{I}$ の加算が同様の役割を果たしている。

Step 4: スケール拘束 (非凸) への対処 この問題は本質的に、零空間の探索 (= システム同定) であるため、 $\mathbf{u} = \mathbf{0}$ という自明な解に潰れるのを防ぐ必要がある。元のモデルでは $\|\mathbf{u}\|_2 = 1$ という球面拘束があるものの、これは non-convex 拘束である。本稿では ADMM の標準的な収束性を崩さないため、「ADMM の 1 ループの終わりに、スパース化された解 $\mathbf{z}$ を射影する」というアプローチを取る。

$$\mathbf{z}^{(k+1)} \leftarrow \frac{\mathbf{z}^{(k+1)}}{\|\mathbf{z}^{(k+1)}\|_2} \quad (18)$$

これにより、自明解をさけながら不要な音漏れだけを排除することを目論む。